

# Dokumentacija projekta: Student Performance Prediction

---

## 1. Uvod

Cilj projekta je predikcija završne ocene učenika, označene atributom **G3**, na osnovu podataka iz skupa **student-por.csv**. Problem je formulisan kao regresioni zadatak, jer se predviđa numerička vrednost ocene na skali od 0 do 20.

Projekat ne posmatra samo najbolju metriku, već i praktičnu upotrebljivost modela. Zbog toga su posebno upoređena dva scenarija:

- **with\_G1\_G2**: model koristi prethodne ocene **G1** i **G2**;
- **without\_G1\_G2**: model ne koristi prethodne ocene **G1** i **G2**.

Ovakvo poređenje je važno zato što **G1** i **G2** nose mnogo informacija o završnoj oceni, ali u nekim praktičnim situacijama te ocene možda još nisu dostupne.

## 2. Opis skupa podataka

Korišćen je skup podataka **data/raw/student-por.csv**. Dataset sadrži podatke o učenicima, njihovom porodičnom okruženju, školskim navikama, izostancima, prethodnim ocenama i završnoj oceni.

Sažetak iz **data/logs/step01\_data\_preparation/dataset\_overview.csv**:

| Opis                               | Vrednost |
|------------------------------------|----------|
| Broj redova                        | 649      |
| Broj kolona                        | 33       |
| Broj numeričkih kolona             | 16       |
| Broj kategorijskih kolona          | 17       |
| Broj duplikata                     | 0        |
| Ukupan broj nedostajućih vrednosti | 0        |
| Minimalna završna ocena <b>G3</b>  | 0        |
| Maksimalna završna ocena <b>G3</b> | 19       |
| Prosečna završna ocena <b>G3</b>   | 11.91    |

Atributi **G1**, **G2** i **G3** predstavljaju ocene učenika:

- **G1**: prva periodična ocena;
- **G2**: druga periodična ocena;
- **G3**: završna ocena i ciljna promenljiva.

Prema `features_overview.csv`, svi atributi osim `G3` mogu biti ulazni atributi u scenariju sa `G1/G2`. U scenariju bez `G1/G2`, iz ulaza se dodatno uklanjaju `G1` i `G2`.

### 3. Početno preprocesiranje podataka

U koraku početne pripreme provereni su nedostajuće vrednosti, duplikati, osnovni opsezi ocena i očigledne anomalije. Prema `data/logs/step01_data_preparation/preprocessing_report.csv`, dataset nema nedostajuće vrednosti ni duplikate, a ocene `G1`, `G2` i `G3` nalaze se u očekivanom opsegu 0-20.

| Provera                         | Rezultat |
|---------------------------------|----------|
| Missing vrednosti               | 0        |
| Duplikati                       | 0        |
| <code>G1</code> van opsega 0-20 | Ne       |
| <code>G2</code> van opsega 0-20 | Ne       |
| <code>G3</code> van opsega 0-20 | Ne       |
| Kandidati za uklanjanje         | Nema     |

Nije bilo očiglednih redova ili atributa za automatsko uklanjanje. Maksimalan broj izostanaka je 32, što se posmatra kao potencijalno ekstremna, ali moguća realna vrednost.


Enkodiranje kategorijskih atributa i skaliranje numeričkih atributa nisu urađeni unapred nad celim datasetom. Umesto toga, `OneHotEncoder` i `StandardScaler` koriste se kasnije unutar `sklearn Pipeline` objekata tokom treniranja modela. Time se sprečava data leakage, jer se transformacije uče samo na trening delu podataka.

### 4. Eksplorativna analiza podataka


Eksplorativna analiza je sprovedena u koraku `step02_eda.py`, a sažetak se nalazi u `data/logs/step02_eda/eda_report.csv`.

| Pokazatelj                                          | Vrednost |
|-----------------------------------------------------|----------|
| Broj učenika                                        | 649      |
| Prosečna <code>G3</code> ocena                      | 11.91    |
| Broj učenika sa <code>G3 = 0</code>                 | 15       |
| Procenat učenika sa <code>G3 = 0</code>             | 2.31%    |
| Korelacija <code>G1</code> i <code>G3</code>        | 0.83     |
| Korelacija <code>G2</code> i <code>G3</code>        | 0.92     |
| Korelacija <code>failures</code> i <code>G3</code>  | -0.39    |
| Korelacija <code>studytime</code> i <code>G3</code> | 0.25     |
| Korelacija <code>absences</code> i <code>G3</code>  | -0.09    |

Distribucija završne ocene prikazuje raspored vrednosti ciljne promenljive:




Korelaciona matrica numeričkih atributa pokazuje da su G1 i naročito G2 najjače povezani sa G3:




Odnos prethodnih ocena i završne ocene dodatno potvrđuje jaku linearnu vezu:

G1 u odnosu na G3




G2 u odnosu na G3




Ostali atributi imaju slabiju, ali korisnu vezu sa završnom ocenom. Broj prethodnih neuspeha (*failures*) ima negativnu korelaciju sa *G3*, dok *studytime* pokazuje pozitivnu, ali znatno slabiju vezu.





Broj izostanaka ima slabu negativnu korelaciju sa završnom ocenom, ali distribucija izostanaka je važna za razumevanje ekstremnijih slučajeva:



Vrednosti poput  $G3 = 0$  i većeg broja izostanaka nisu automatski obrisane, jer mogu predstavljati realne slučajeve u obrazovnom kontekstu.

## 5. Podela podataka

Dataset je jednom podeljen na trening, validacioni i test skup. Izveštaj se nalazi u [data/logs/step03\\_data\\_split/split\\_report.csv](#).

| Skup       | Broj redova | Procenat |
|------------|-------------|----------|
| Train      | 454         | 69.95%   |
| Validation | 97          | 14.95%   |
| Test       | 98          | 15.10%   |

Svi modeli i svi scenariji koriste iste redove iz ove podele. Time je poređenje modela fer i ponovljivo. Validacioni skup se koristi za izbor modela i hiperparametara, dok se test skup koristi za finalnu proveru performansi.

## 6. Odabir i treniranje modela

U početnom poređenju trenirana su tri modela:

- **DummyRegressor**: baseline model koji služi za proveru da li ostali modeli uče koristan signal;
- **Ridge Regression**: linearni model sa regularizacijom;
- **RandomForestRegressor**: ansambl model koji može uhvatiti nelinearne zavisnosti.

Korišćene metrike su:


- MAE: prosečna apsolutna greška;
- RMSE: koren srednje kvadratne greške;
- R2: procenat objašnjene varijanse.

Sažetak iz [data/logs/step04\\_model\\_training/model\\_comparison\\_report.csv](#):


| Scenario      | Model                 | Validation RMSE | Validation R2 | Test RMSE | Test R2 |
|---------------|-----------------------|-----------------|---------------|-----------|---------|
| with_G1_G2    | DummyRegressor        | 3.1360          | -0.0004       | 3.5229    | -0.0291 |
| with_G1_G2    | Ridge Regression      | 1.0555          | 0.8867        | 1.3314    | 0.8530  |
| with_G1_G2    | RandomForestRegressor | 0.9862          | 0.9011        | 1.3905    | 0.8397  |
| without_G1_G2 | DummyRegressor        | 3.1360          | -0.0004       | 3.5229    | -0.0291 |
| without_G1_G2 | Ridge Regression      | 2.8668          | 0.1639        | 3.0243    | 0.2416  |
| without_G1_G2 | RandomForestRegressor | 2.7779          | 0.2150        | 2.9105    | 0.2976  |



Poređenje modela na validation skupu



Poređenje modela na test skupu



Modeli sa **G1** i **G2** ostvaruju znatno bolje rezultate. To je očekivano, jer prethodne ocene imaju direktnu i jaku vezu sa završnom ocenom. Bez **G1/G2**, modeli i dalje nadmašuju baseline, ali sa mnogo skromnijim **R2** vrednostima.

## 7. Podešavanje hiperparametara


Podešavanje hiperparametara sprovedeno je pomoću validacionog skupa. Test skup nije korišćen za izbor hiperparametara, već samo za proveru nakon izbora.

Sažetak iz [data/logs/step06\\_hyperparameter\\_tuning/hyperparameter\\_tuning\\_summary.csv](#):


| Scenario      | Model                 | Najbolji parametri                                                           | Validation RMSE | Test RMSE | Test R2 |
|---------------|-----------------------|------------------------------------------------------------------------------|-----------------|-----------|---------|
| with_G1_G2    | Ridge Regression      | <b>alpha=10.0</b>                                                            | 1.0457          | 1.3370    | 0.8518  |
| with_G1_G2    | RandomForestRegressor | <b>n_estimators=100;</b><br><b>max_depth=5;</b><br><b>min_samples_leaf=5</b> | 0.8831          | 1.4138    | 0.8343  |
| without_G1_G2 | Ridge Regression      | <b>alpha=100.0</b>                                                           | 2.7782          | 2.9202    | 0.2929  |

| Scenario      | Model                 | Najbolji parametri                                                                              | Validation RMSE | Test RMSE | Test R2 |
|---------------|-----------------------|-------------------------------------------------------------------------------------------------|-----------------|-----------|---------|
| without_G1_G2 | RandomForestRegressor | <code>n_estimators=100;</code><br><code>max_depth=10;</code><br><code>min_samples_leaf=2</code> | 2.7633          | 2.9108    | 0.2974  |

Default vs tuned modeli na validation skupu



Default vs tuned modeli na test skupu



Tuning donosi poboljšanje, posebno za `RandomForestRegressor` u scenariju sa `G1/G2`, gde validacioni RMSE pada sa 0.9862 na 0.8831. Ipak, razlika između validacionog i test rezultata pokazuje da izbor finalnog modela ne treba zasnivati samo na jednoj metrici, već i na generalizaciji, jednostavnosti i praktičnoj interpretabilnosti.


## 8. Analiza značajnosti atributa

Za procenu važnosti atributa korišćen je `RandomForestRegressor`. Rezultati se nalaze u:


- `data/logs/step08_feature_importance/feature_importance_with_G1_G2.csv;`
- `data/logs/step08_feature_importance/feature_importance_without_G1_G2.csv.`

U scenariju sa `G1/G2`, najvažniji atribut je `G2`, sa značajem 0.896595. Nakon njega slede `absences`, `G1`, `age` i `reason`.

## Random Forest feature importance



U scenariju bez G1/G2, model se oslanja na druge osobine učenika. Najvažniji atribut je failures, zatim reason, absences, school, higher, age, Fedu, health, Dalc i studytime.



Ovaj deo projekta ispunjava zahtev za odabir najznačajnijih atributa i dodatno objašnjava zašto se performanse značajno razlikuju između dva scenarija.

## 9. Top features scenario

U ovom koraku provereno je da li manji broj najvažnijih atributa može dati slične ili bolje rezultate od kompletnog skupa atributa. Korišćeni su fajlovi:

- `data/logs/step09_top_features/top_features_with_G1_G2.csv`;
- `data/logs/step09_top_features/top_features_without_G1_G2.csv`;
- `data/logs/step09_top_features/top_features_tuning_details.csv`;
- `data/logs/step09_top_features/top_features_model_comparison_report.csv`.

Top 10 atributa u scenariju sa G1/G2 su: G2, absences, G1, age, reason, freetime, health, Fedu, school i failures.


Top 10 atributa u scenariju bez G1/G2 su: failures, reason, absences, school, higher, age, Fedu, health, Dalc i studytime.

Sažetak poređenja:

| Scenario                | Model            | Validation RMSE | Test RMSE | Test R2 |
|-------------------------|------------------|-----------------|-----------|---------|
| with_G1_G2              | Ridge Regression | 1.0457          | 1.3370    | 0.8518  |
| top_features_with_G1_G2 | Ridge Regression | 0.9735          | 1.2796    | 0.8642  |

| Scenario                   | Model                 | Validation RMSE | Test RMSE | Test R2 |
|----------------------------|-----------------------|-----------------|-----------|---------|
| with_G1_G2                 | RandomForestRegressor | 0.8831          | 1.4138    | 0.8343  |
| top_features_with_G1_G2    | RandomForestRegressor | 0.8656          | 1.4313    | 0.8301  |
| without_G1_G2              | Ridge Regression      | 2.7782          | 2.9202    | 0.2929  |
| top_features_without_G1_G2 | Ridge Regression      | 2.7461          | 3.0485    | 0.2294  |
| without_G1_G2              | RandomForestRegressor | 2.7633          | 2.9108    | 0.2974  |
| top_features_without_G1_G2 | RandomForestRegressor | 2.7076          | 3.0354    | 0.2360  |

Poredjenje tuned top\_features scenarija na validation skupu



Poredjenje tuned top\_features scenarija na test skupu



Top features pristup je posebno uspešan u scenariju sa G1/G2. Ridge Regression sa top atributima postiže bolji test RMSE od punog modela i koristi samo 10 atributa, što ga čini jednostavnijim za upotrebu i tumačenje.


## 10. Izbor finalnog modela i analiza predikcija

Finalni model je eksportovan u `models/final/final_model.joblib`. Prema `data/logs/step10_final_model_selection/final_model_report.csv`, izabran je:


| Stavka    | Vrednost                |
|-----------|-------------------------|
| Scenario  | top_features_with_G1_G2 |
| Model     | Ridge Regression        |
| Parametar | alpha=0.01              |

| Stavka          | Vrednost |
|-----------------|----------|
| Final test MAE  | 0.7655   |
| Final test RMSE | 1.2737   |
| Final test R2   | 0.8655   |

Model je izabran jer daje jak validacioni rezultat, najbolji test RMSE među poređenim kandidatima, koristi samo 10 atributa i jednostavniji je za tumačenje od Random Forest modela. Praktično ograničenje je da koristi G1 i G2.




Graf stvarnih i predviđenih vrednosti pokazuje koliko su predikcije blizu idealne dijagonale. Što su tačke bliže dijagonali, model bolje predviđa završnu ocenu.



Residual graf prikazuje razlike između stvarne i predviđene vrednosti. Residual je definisan kao:

```
residual = stvarna G3 - predviđena G3
```



MAE od 0.7655 znači da model u proseku greši za manje od jedne ocene. RMSE od 1.2737 pokazuje da postoje pojedinačni slučajevi sa većom greškom, ali ukupno greške ostaju relativno male. R2 od 0.8655 znači da model objašnjava veliki deo varijanse završne ocene na test skupu.

## 11. Deployment modela

Finalni model se nalazi u folderu `models/final/`. Projekat sadrži pomoćne fajlove za korišćenje modela:

- `src/model_usage.py`: učitavanje modela, priprema ulaza i formatiranje predikcije;
- `src/predict.py`: CLI primer za predikciju;
- `src/streamlit_app.py`: Streamlit aplikacija za unos podataka i prikaz predikcije.

Predikcija iz terminala može se pokrenuti komandom:

```
.\.venv\Scripts\python.exe .\src\predict.py
```

Primer sa eksplicitnim argumentima:

```
.\.venv\Scripts\python.exe .\src\predict.py --G2 13 --absences 6 --G1 12 --age 15  
--reason other --freetime 3 --health 3 --Fedu 1 --school GP --failures 0
```

Streamlit aplikacija se pokreće komandom:



```
streamlit run .\src\streamlit_app.py
```

Korisnik može uneti vrednosti atributa i dobiti predikciju završne ocene **G3**.

## 12. Diskusija rezultata

Poređenje scenarija sa i bez **G1/G2** pokazuje jasnu razliku. Model sa **G1/G2** je precizniji jer prethodne ocene nose mnogo informacija o završnoj oceni. To potvrđuju i korelacije iz EDA faze: **G2** ima korelaciju 0.92 sa **G3**, a **G1** korelaciju 0.83 sa **G3**.

Scenario bez **G1/G2** ima slabije performanse, ali nije bez praktične vrednosti. On može biti koristan za raniju procenu uspeha učenika, kada prethodne ocene još nisu dostupne. U tom slučaju model se oslanja na informacije kao što su prethodni neuspesi, izostanci, razlog izbora škole, želja za višim obrazovanjem, starost i navike u učenju.

Finalni model može pomoći kao podrška u proceni rizika i očekivanog uspeha, ali ne treba da bude jedini osnov za donošenje odluka. Obrazovni kontekst uključuje faktore koje dataset ne mora potpuno da obuhvati, kao što su promene motivacije, zdravstvene okolnosti, kvalitet nastave, podrška nastavnika i vanredni događaji.

Glavna ograničenja modela su:

- skup podataka je ograničen na dostupne attribute;
- finalni model koristi **G1** i **G2**, pa nije pogodan za procenu pre pojave tih ocena;
- model predviđa numeričku ocenu, ali ne objašnjava uvek uzrok slabog ili dobrog uspeha;
- rezultati zavise od kvaliteta i reprezentativnosti originalnog dataset-a.

Moguća buduća unapređenja uključuju rad sa većim i raznovrsnijim podacima, dodatne modele, detaljniju validaciju na spoljnim podacima i razvoj posebnog modela za ranu identifikaciju učenika pod rizikom.

## 13. Zaključak

U projektu je pripremljen i analiziran dataset **student-por.csv**. Urađeno je početno preprocesiranje, provereni su nedostajuće vrednosti, duplikati i osnovne anomalije, a transformacije su pravilno pomerene u **Pipeline** kako bi se izbegao data leakage.

Sprovedena je eksplorativna analiza, trenirano je više modela, izvršeno je poređenje performansi, podešeni su hiperparametri i analizirana je važnost atributa. Posebno su upoređeni scenariji sa i bez **G1/G2**, kao i modeli sa svim atributima i modeli sa najznačajnijim atributima.

Finalni model je **Ridge Regression** u scenariju **top\_features\_with\_G1\_G2**, eksportovan u **models/final/final\_model.joblib**. Model ostvaruje dobre rezultate na test skupu, sa MAE 0.7655, RMSE 1.2737 i R2 0.8655. Praktična upotrebljivost modela zavisi od dostupnosti atributa **G1** i **G2**: sa njima je model znatno precizniji, dok scenario bez njih ostaje koristan za raniju, manje preciznu procenu uspeha učenika.