

Student Performance Prediction

SAUSAU predmetni projekat

Opis problema

Predmetni projekat podrazumeva razvoj modela za predikciju završne ocene učenika na kraju školske godine. Skup podataka je prikupljen u okviru istraživanja o školskom uspehu učenika u srednjim školama u Portugalu. Podaci potiču iz školskih izveštaja i upitnika i obuhvataju rezultate iz Matematike (mat) i Portugalskog jezika (por).

Dataset sadrži demografske, socijalne i školske karakteristike učenika, uključujući pol, godine, obrazovanje roditelja, dodatnu podršku, navike u učenju, zdravstveno stanje, izostanke i ocene tokom školske godine.

Ciljana promenljiva je **G3**, odnosno završna ocena učenika na kraju godine. U okviru projekta potrebno je razviti model koji na osnovu dostupnih atributa predviđa vrednost ove ocene.

Posebnu pažnju treba obratiti na attribute **G1** i **G2**, koji predstavljaju ocene iz prvog i drugog polugodišta. Pošto su ove ocene visoko korelisane sa završnom ocenom **G3**, njihovo korišćenje može značajno olakšati predikciju. Međutim, praktično korisniji pristup je analiza i razvoj modela koji predviđa **G3** bez direktnog oslanjanja na attribute **G1** i **G2**.

Pregled atributa i njihovo značenje

Dataset obuhvata sledeće attribute:

- **sex** - pol učenika
- **age** - starost učenika
- **address** - tip adrese stanovanja
- **famsize** - veličina porodice
- **Pstatus** - status zajedničkog života roditelja
- **Medu** - obrazovanje majke
- **Fedu** - obrazovanje oca
- **Mjob** - zanimanje majke
- **Fjob** - zanimanje oca
- **reason** - razlog izbora škole
- **guardian** - staratelj učenika
- **traveltime** - vreme putovanja od kuće do škole
- **studytime** - nedeljno vreme učenja
- **failures** - broj prethodnih neuspeha
- **schoolsup** - dodatna obrazovna podrška
- **famsup** - obrazovna podrška porodice
- **paid** - dodatni plaćeni časovi iz predmeta

- **activities** - vannastavne aktivnosti
- **nursery** - pohađanje vrtića
- **higher** - planovi za visoko obrazovanje
- **internet** - internet kod kuće
- **romantic** - romantična veza
- **famrel** - kvalitet porodičnih odnosa
- **freetime** - slobodno vreme posle škole
- **goout** - učestalost izlazaka sa prijateljima
- **Dalc** - konzumacija alkohola radnim danima
- **Walc** - konzumacija alkohola vikendom
- **health** - zdravstveno stanje
- **absences** - broj izostanaka iz škole
- **G1** - ocena na kraju prvog polugodišta
- **G2** - ocena na kraju drugog polugodišta
- **G3** - završna ocena na kraju godine, odnosno ciljana promenljiva

Očekivani izlazi

U okviru projekta očekuje se:

- razvoj modela za predikciju završne ocene učenika **G3**;
- analiza uticaja atributa **G1** i **G2** na rezultat predikcije;
- poređenje pristupa u kojem se **G1** i **G2** koriste sa pristupom u kojem se ovi atributi izostavljaju;
- vizuelna analiza podataka, posebno odnosa između pojedinačnih atributa i završne ocene;
- prikaz i tumačenje atributa koji imaju najveći značaj za predikciju;
- jasno obrazloženje dobijenih rezultata i ograničenja modela.

Zahtevi za procesiranje podataka

Pre treniranja modela potrebno je izvršiti početnu obradu podataka. Posebno je potrebno:

- proveriti da li u skupu postoje nedostajuće vrednosti ili anomalije;
- obraditi kategorijske attribute tako da budu pogodni za korišćenje u modelu;
- analizirati korelaciju između atributa, posebno korelaciju atributa **G1**, **G2** i **G3**;
- doneti i obrazložiti odluku da li se atributi **G1** i **G2** koriste u modelu;
- po potrebi ukloniti ili transformisati attribute koji nisu korisni za formiranje izlaza;
- podeliti podatke na skup za obučavanje i skup za testiranje.

Dokumentovanje rezultata

Rezultati projekta treba da budu jasno prikazani kroz tekst, tabele i grafike. Dokumentacija treba da sadrži:

- opis korišćenog skupa podataka;
- objašnjenje izvršene obrade podataka;
- prikaz najvažnijih rezultata eksplorativne analize;
- opis korišćenog modela ili modela;
- prikaz performansi modela;
- poređenje rezultata sa i bez korišćenja atributa **G1** i **G2**;
- tumačenje dobijenih rezultata;
- zaključak o tome koliko je model praktično upotrebljiv za predikciju završne ocene učenika.